



Rapport de stage

Migration et modernisation des processus ETL de R vers
Python

Présenté par : Kévin SU

Formation : Master 2 InformatiqueDataScale

Entreprise : X-FAB

Tuteur pédagogique : Corentin BRESELLE

Tuteur entreprise : Aurélie Uemura, Manager YE PCM & Digital Support

Année universitaire 2025–2026

Résumé

Dans le cadre de ce projet de fin d'études réalisé au cours d'un stage de six mois au sein de X-FAB, l'objectif principal a été de contribuer à la modernisation des processus de traitement de données existants, notamment à travers la migration de plusieurs pipelines ETL développés en R vers Python.

Dans un premier temps, le travail a porté sur la migration d'une dizaine de pipelines ETL. Les traitements ont été réimplémentés en Python en veillant à préserver la logique métier ainsi que le comportement des traitements d'origine. Des tests de comparaison et de non-régression ont également été réalisés afin de garantir la cohérence des résultats entre les versions R et Python.

Dans un second temps, le projet s'est orienté vers l'intégration d'outils modernes de Data Engineering tels que Prefect, Docker et GitLab. Ces outils ont permis de mieux structurer l'exécution, le déploiement et la gestion du code des différents traitements. Cette démarche de migration et de modernisation permet ainsi de disposer de traitements plus maintenables, évolutifs et plus facilement intégrables dans une architecture Data moderne.

Remerciements

Je tiens tout d'abord à remercier l'ensemble des personnes qui ont contribué au bon déroulement de mon projet de fin d'études réalisé au sein de X-FAB.

Mes premiers remerciements s'adressent à Madame Aurélie Uemura, Manager YE PCM Digital Support, pour la confiance qu'elle m'a accordée et pour m'avoir donné l'opportunité d'effectuer mon stage au sein de son équipe.

Je tiens tout particulièrement à remercier Monsieur Corentin Breselle, mon tuteur de stage, pour le temps qu'il m'a consacré dès mon arrivée, pour sa disponibilité ainsi que pour son accompagnement tout au long du projet. Ses conseils et son soutien m'ont permis de mieux comprendre les enjeux techniques et métiers liés au traitement des données dans un environnement industriel.

Je souhaite également remercier l'ensemble de l'équipe pour son accueil, sa disponibilité et son accompagnement durant cette période. Les échanges, les conseils et le partage d'expérience de chacun ont largement contribué à mon intégration ainsi qu'à l'avancement de mes travaux.

J'adresse également mes remerciements à mon encadrant académique ainsi qu'à l'ensemble des enseignants ayant participé à ma formation, pour les connaissances et les compétences acquises tout au long de mon cursus.

Enfin, j'adresse mes sincères remerciements à mes parents, à mes proches et à mes amis pour leurs encouragements, leur aide et leur soutien tout au long de cette année de formation.

Table des matières

Résumé	1
Remerciements	2
1 Introduction	5
2 Présentation de l'entreprise et de l'environnement de travail	6
2.1 L'entreprise X-FAB	6
2.1.1 X-FAB en bref	6
2.1.2 X-Fab en chiffre (2025)	6
2.1.3 Vision et valeurs	7
2.1.4 Activités et marchés	7
2.1.5 X-FAB France	9
2.2 Organisation	10
2.2.1 Structure générale de X-FAB France	10
2.2.2 Présentation du pôle d'accueil	10
2.2.3 Organigramme du pôle d'accueil	12
3 Contexte du stage	13
3.1 Objectifs et organisation du stage	14
3.1.1 Objectifs du stage	14
3.1.2 Organisation et suivi du projet	15
3.2 Environnement technique et outils utilisés	16
3.2.1 DataMart	16
3.2.2 Principales bibliothèques Python utilisées	17
3.2.3 Orchestration avec Prefect	18
3.2.4 Conteneurisation avec Docker	20
3.2.5 Outils de gestion et de collaboration	20
3.3 Stratégie de validation et tests	22
3.3.1 Bilan de la validation	23
3.4 Travaux complémentaires	23

3.5	Travaux complémentaires	23
3.5.1	ETL Reject	24
3.5.2	ETL Inline	24
3.6	Difficultés rencontrées	25
3.6.1	Délais liés à la mise en production	25
3.6.2	Optimisation des traitements de nettoyage du DataMart	25
3.7	Conclusion	26
A	Annexes	27

1. Introduction

Dans le cadre de ma formation en Master 2 DataScale, j’ai effectué mon stage de fin d’études au sein de X-FAB France, d’avril à septembre 2026.

Dans un contexte où les entreprises industrielles génèrent et exploitent des volumes de données de plus en plus importants, la fiabilité, la maintenabilité et l’évolution des traitements de données constituent des enjeux majeurs. Les architectures Data modernes doivent ainsi permettre de collecter, transformer et mettre à disposition les données de manière fiable et automatisée.

Dans ce cadre, les processus ETL (*Extract, Transform, Load*) occupent une place essentielle. Ils permettent d’extraire des données provenant de différentes sources, de leur appliquer des transformations afin de les rendre exploitables, puis de les charger dans des systèmes de stockage ou d’analyse.

Au sein de X-FAB, plusieurs traitements ETL historiques ont été développés en langage R afin de répondre à différents besoins liés à l’exploitation des données industrielles. Avec l’évolution des usages, des technologies et des pratiques de Data Engineering, la migration de ces traitements vers Python s’inscrit dans une démarche de modernisation, de standardisation et d’amélioration de leur maintenabilité.

Dans ce contexte, X-FAB a engagé une migration progressive de ses traitements ETL existants de R vers Python. La problématique principale de ce projet peut ainsi être formulée de la manière suivante :

« Comment migrer efficacement des processus ETL existants, développés en R vers Python, vers une architecture Big Data moderne ? »

Afin de répondre à cette problématique, ce rapport est structuré en quatre grandes parties. La première présente X-FAB ainsi que l’environnement dans lequel s’est déroulé le stage. La deuxième expose le contexte du projet, ses objectifs, son organisation et les technologies utilisées. La troisième partie présente de manière détaillée les solutions mises en œuvre. Enfin, la dernière partie revient sur les difficultés rencontrées au cours du projet, les solutions apportées ainsi que les perspectives d’évolution.

2. Présentation de l'entreprise et de l'environnement de travail

2.1 L'entreprise X-FAB

2.1.1 X-FAB en bref

Créé en 1992 à Erfurt en Allemagne, X-FAB Silicon Foundries SE est un groupe international spécialisé dans la fabrication de semi-conducteurs analogique, mixtes et MEMS (micro-Electro-Mechanical Systems)

Notre site X-FAB France, est le plus recent site de la société qui a repris les actif de d'Altis Semiconductor en 2016 et deviens le sixieme site de production de la société et l'année suivante, le groupe s'introduit à la bourse de Paris.

2.1.2 X-Fab en chiffre (2025)

- plus de **30 années d'expérience** dans l'industrie des semi-conducteurs ;
- **6 sites de production** répartis dans quatre pays : l'Allemagne avec trois sites, la France, les États-Unis et la Malaisie ;
- environ **870 millions de dollars de chiffre d'affaires** ;
- près de **4,300 collaborateurs** dans le monde ;
- plus de **45 nationalités** représentées au sein du groupe.




FIGURE 2.1 – X-FAB en chiffre

2.1.3 Vision et valeurs

La vision de X-FAB s'exprime à travers la devise suivante :

“To be the foundry of choice for the analog world”

Afin de soutenir cette ambition, l'entreprise s'appuie sur une culture favorisant la collaboration, l'entraide et le respect entre les collaborateurs. Cette culture repose sur cinq valeurs principales :

- **Teamwork** : favoriser le travail en équipe, la coopération et le partage des connaissances ;
- **Integrity & Respect** : agir avec intégrité tout en respectant les personnes, les engagements et les règles ;
- **Commitment** : faire preuve d'implication, de responsabilité et de rigueur dans les missions réalisées ;
- **Innovation** : encourager l'amélioration continue, la créativité et la recherche de nouvelles solutions ;
- **Customer Orientation** : placer les besoins et la satisfaction des clients au cœur des décisions et des actions.

2.1.4 Activités et marchés

Un **semi-conducteur** est un matériau utilisé pour fabriquer des composants électroniques. Il sert notamment à créer des **puces électroniques**, qui permettent de traiter, contrôler ou transmettre des informations dans de nombreux appareils.

X-FAB est spécialisée dans la fabrication de semi-conducteurs, notamment dans les technologies **analogiques et mixed-signal**. Ces technologies permettent de traiter des informations provenant du monde réel, comme une température, une pression, une tension électrique ou un mouvement.

Les circuits analogiques traitent des signaux continus, tandis que les circuits *mixed-signal* combinent des fonctions analogiques et numériques sur une même puce. Ils permettent donc de faire le lien entre un capteur et un système numérique capable d'analyser les informations reçues.

X-FAB utilise plusieurs technologies de fabrication de semi-conducteurs.

— **CMOS** (*Complementary Metal-Oxide-Semiconductor*) :

il s'agit d'une technologie très utilisée pour fabriquer des circuits intégrés. Elle permet de créer des puces qui consomment peu d'énergie et qui peuvent regrouper plusieurs fonctions électroniques.

— **SOI** (*Silicon On Insulator*) :

cette technologie utilise une couche de silicium isolée du reste du matériau. Cela permet notamment d'améliorer les performances électriques et de limiter certaines pertes d'énergie.

— **Technologies analogiques et mixed-signal** :

elles permettent de mesurer, amplifier ou convertir des signaux provenant de capteurs. Elles sont utilisées, par exemple, pour traiter une température, une pression ou une tension électrique.

— **MEMS** (*Micro-Electro-Mechanical Systems*) :

les MEMS sont de très petits systèmes qui combinent des éléments mécaniques et électroniques. Ils peuvent servir à mesurer un mouvement, une vibration, une pression ou une accélération.

Les activités de X-FAB sont principalement orientées vers trois grands marchés : **l'automobile, l'industrie et le médical**.

Dans le secteur **automobile**, les composants fabriqués peuvent être intégrés dans différents systèmes électroniques embarqués, comme les capteurs, les systèmes de gestion de puissance, les dispositifs d'aide à la conduite ou encore certains systèmes de contrôle.

Dans le secteur **industriel**, les technologies proposées sont utilisées dans des applications nécessitant des circuits fiables, performants et capables de fonctionner dans des environnements exigeants. Elles peuvent par exemple intervenir dans les systèmes d'automatisation, les équipements de mesure ou les dispositifs de contrôle.

Enfin, dans le domaine **médical**, les technologies de X-FAB participent au développement de dispositifs nécessitant une grande précision et une forte fiabilité. Elles peuvent notamment être utilisées dans des systèmes de détection, de mesure, de diagnostic ou

dans différents microsystèmes destinés aux équipements médicaux.

Ainsi, X-FAB se positionne comme une fonderie spécialisée dans des technologies destinées à connecter les phénomènes physiques du monde réel aux systèmes électroniques numériques.

2.1.5 X-FAB France

Le présent stage a été réalisé sur le site de **X-FAB France**, situé à Corbeil-Essonnes, dans le département de l'Essonne, au sud de Paris. Il s'agit du plus grand site de production européen du groupe X-FAB. Le site est dirigé par M. Sébastien Daveau, nommé Chief Executive Officer de X-FAB France à compter du 1^{er} août 2023.

L'activité principale du site est consacrée à la **fabrication de wafers semi-conducteurs**. Un wafer est une fine plaque de matériau semi-conducteur, généralement constituée de silicium, sur laquelle sont fabriqués simultanément un grand nombre de circuits intégrés.

Chaque wafer est composé de nombreuses petites unités appelées **dies**. Un die correspond à une puce individuelle avant sa découpe et son conditionnement final. Sa fabrication nécessite une succession d'étapes technologiques complexes, réalisées à l'aide d'équipements industriels particulièrement précis et coûteux. La maîtrise de la qualité tout au long du processus de fabrication constitue donc un enjeu économique majeur.




FIGURE 2.2 – Exemple de wafer composé de plusieurs dies

Dans ce contexte, la notion de **yield**, ou rendement de production, occupe une place

essentielle. Le yield représente la proportion de dies conformes et fonctionnels obtenus à l'issue des différentes étapes de fabrication et de test. Un nombre important de dies défectueux entraîne une diminution du rendement et peut donc avoir un impact économique significatif. Le suivi et l'amélioration du yield constituent ainsi des objectifs majeurs dans l'industrie des semi-conducteurs.

La fabrication des wafers repose sur une succession d'opérations technologiques réalisées dans un environnement fortement contrôlé, notamment en salle blanche. Parmi les principales étapes figurent le dépôt de matériaux, la photolithographie, la gravure, l'implantation ionique ainsi que différents traitements thermiques. Chacune de ces étapes peut influencer les caractéristiques électriques et la qualité finale des circuits produits.

2.2 Organisation

2.2.1 Structure générale de X-FAB France

X-FAB France est organisée autour de plusieurs grandes directions, parmi lesquelles la Production, les Opérations Process & Équipement, le Yield Enhancement & Process Integration, la Recherche et Développement (R&D), la Qualité, les Infrastructures, Services Généraux & IT, les Ressources Humaines & la Paie, la Finance, les Achats ainsi que le Service Client.

Le présent stage a été réalisé au sein du service **YE PCM & Digital Support**, rattaché au pôle **Yield Enhancement & Process Integration (YE)**. Ce pôle a pour mission principale de contribuer à l'amélioration continue des rendements de production en s'appuyant à la fois sur l'analyse des données, le suivi des procédés et le développement de solutions de support aux équipes d'ingénierie.

Le pôle Yield Enhancement & Process Integration est dirigé par **Madame Laurianne Denis**, Directrice Yield Enhancement. Mon stage s'inscrit donc dans un environnement où l'exploitation, la fiabilité et l'amélioration continue des données industrielles jouent un rôle essentiel dans la performance globale du site.

2.2.2 Présentation du pôle d'accueil

Mon projet de fin d'études a été réalisé au sein d'un pôle placé sous la responsabilité de **Madame Aurélie Uemura**, manager d'une équipe regroupant environ une vingtaine de collaborateurs.

Ce pôle est organisé autour de trois équipes complémentaires : **PCM Process Test**, **PCM Data Analytics** et **YE Digital Support**. Leur collaboration permet d'as-

surer à la fois la réalisation des tests électriques sur les wafers, l'analyse des données issues de ces tests et le développement de solutions numériques destinées aux équipes d'ingénierie et de production.

PCM Process Test

L'équipe **PCM Process Test** est chargée de réaliser des tests électriques sur les wafers au cours du processus de fabrication.

Elle effectue notamment des mesures **PCM** (*Process Control Monitoring*), dont l'objectif est de contrôler différents paramètres électriques et technologiques liés au procédé de fabrication.

Ces mesures permettent de vérifier que le procédé reste conforme aux spécifications définies et d'identifier d'éventuelles anomalies ou dérives susceptibles d'avoir un impact sur la qualité des wafers et des dies produits.

PCM Data Analytics

L'équipe **PCM Data Analytics** exploite les données générées par les tests PCM.

Son rôle consiste notamment à analyser les résultats obtenus, à suivre l'évolution des paramètres de fabrication et à détecter d'éventuelles dérives du procédé.

Elle participe également à la création et à la mise à disposition d'indicateurs et d'outils de reporting permettant aux équipes d'ingénierie de suivre l'état des procédés et d'appuyer leurs analyses.

Cette équipe constitue ainsi un lien essentiel entre les données issues des tests électriques et leur exploitation dans le cadre du suivi et de l'amélioration des procédés industriels.

YE Digital Support

L'équipe **YE Digital Support** est chargée de développer et de maintenir des solutions numériques destinées à accompagner les différentes équipes métier.

Elle intervient notamment dans le développement d'applications internes, l'automatisation de traitements ainsi que dans la mise à disposition de données nécessaires aux équipes **Yield Engineering (YE)**, **Operations** et **Quality Assurance (QA)**.

Les solutions développées permettent de réduire certaines tâches manuelles, de faciliter l'accès aux données et d'améliorer l'efficacité des analyses réalisées par les équipes d'ingénierie.

C'est au sein de cette équipe **YE Digital Support** que j'ai réalisé mon projet de

fin d'études. Mes missions se sont principalement inscrites dans le domaine du **Data Engineering**, avec pour objectif de contribuer à la modernisation, à l'automatisation et à l'industrialisation de traitements de données existants.

2.2.3 Organigramme du pôle d'accueil

La figure suivante présente de manière synthétique la hiérarchie du pôle ainsi que la composition de l'équipe Digital Support dans laquelle j'ai effectué mon stage.




FIGURE 2.3 – Organigramme simplifié du pôle d'accueil

3. Contexte du stage

Au sein de X-FAB France, de nombreux traitements de données sont utilisés afin de collecter, transformer et mettre à disposition les informations nécessaires aux différentes équipes d'ingénierie, d'analyse et de production.

Une partie de ces traitements a été développée en langage **R**, sous la forme de scripts ETL. Ces scripts permettent notamment d'extraire des données provenant de différentes sources, d'appliquer des transformations, puis de charger principalement les résultats dans un **DataMart** regroupant des données liées à la performance des produits.

Ces traitements répondent aux besoins fonctionnels existants et restent pleinement opérationnels. La migration vers Python s'inscrit avant tout dans une démarche d'harmonisation de l'environnement technique avec les autres équipes de X-FAB, notamment les équipes IT, qui utilisent principalement Python.

Dans une démarche de modernisation de son environnement Data, X-FAB souhaite progressivement faire évoluer ces traitements vers **Python**, un langage aujourd'hui largement utilisé dans les domaines du Data Engineering, de l'automatisation et du développement logiciel.

Cette évolution vise à améliorer la maintenabilité du code, à faciliter son intégration avec des outils modernes d'orchestration et de déploiement.

Le fonctionnement général de ces traitements peut être représenté de manière simplifiée par la chaîne suivante :




FIGURE 3.1 – Fonctionnement général d'un traitement ETL

3.1 Objectifs et organisation du stage

3.1.1 Objectifs du stage

L'objectif principal de ce projet de fin d'études est de **migrer une dizaine de traitements ETL existants développés en R vers Python**.

Le stage a débuté le **16 avril 2026** et s'achève le **30 septembre 2026**.

Pour atteindre cet objectif, chaque ETL suit un cycle de migration composé de plusieurs étapes :

1. **Analyse du script R existant** afin d'identifier sa structure, ses données d'entrée et ses sorties ;
2. **Compréhension des règles métier** appliquées au cours du traitement ;
3. **Développement et optimisation des performances de la version Python** en reproduisant le comportement du traitement d'origine ;
4. **Mise en place de tests unitaires** afin de valider les différentes fonctions ;
5. **Comparaison des résultats R et Python** à travers des tests ;
6. **Dockerisation** afin de garantir un environnement d'exécution reproductible ;
7. **Intégration dans l'orchestrateur** afin de gérer son ordonnancement et de superviser son fonctionnement ;
8. **Documentation** du traitement et de son fonctionnement dans Confluence ;
9. **Déploiement en production** après validation des résultats.

Cette démarche permet de structurer la migration de manière progressive et de s'assurer que chaque ETL est correctement analysé, développé, validé et documenté avant sa mise en production.

3.1.2 Organisation et suivi du projet

Le projet a été réalisé selon une organisation inspirée de la méthode **Scrum**, afin de faciliter le suivi de l'avancement, la priorisation des tâches et l'adaptation aux différents besoins rencontrés au cours du stage.


Scrum est une méthode agile basée sur un travail organisé par cycles courts, appelés *sprints*, au cours desquels les tâches sont priorisées, réalisées puis réévaluées régulièrement. Elle favorise la collaboration, la visibilité sur l'avancement du projet et l'adaptation rapide aux éventuels changements de priorité.

Les différentes tâches liées à la migration des ETL sont suivies à l'aide de **Jira**. Cet outil permet de centraliser les travaux à réaliser, de suivre leur état d'avancement et de conserver une visibilité sur les différentes étapes du projet.

Un point d'avancement régulier est également organisé avec mon tuteur de stage. Ces échanges permettent de faire le bilan des travaux réalisés, de discuter des éventuelles difficultés rencontrées et de définir les prochaines priorités.

En complément, une réunion hebdomadaire est organisée avec l'ensemble de l'équipe. Chaque membre y présente les principales tâches réalisées au cours de la semaine précédente ainsi que les travaux prévus pour la semaine suivante.

Afin d'atteindre les objectifs fixés, il a été nécessaire de planifier et de structurer les tâches à réaliser tout au long du stage. La figure suivante présente le planning final simplifié du projet ainsi que la répartition dans le temps des différents ETL à migrer.



Légende : ■ Migration des ETL ■ Travaux complémentaires

FIGURE 3.2 – Diagramme de Gantt

3.2 Environnement technique et outils utilisés

Dans le cadre de la migration des traitements ETL de R vers Python, un nouvel environnement technique a été mis en place.

Cet environnement repose principalement sur une **machine virtuelle Linux distante**, accessible en **SSH**. Le développement est réalisé à distance depuis Visual Studio Code, ce qui permet de travailler directement sur l'environnement cible tout en bénéficiant des fonctionnalités d'un environnement de développement intégré.

L'environnement technique mis en place peut être résumé de la manière suivante :

- machine virtuelle Linux distante ;
- accès sécurisé via SSH ;
- développement avec Visual Studio Code ;
- Python 3.12 ;
- gestion du code avec Git et GitLab ;
- orchestration des traitements avec Prefect ;
- conteneurisation avec Docker.

3.2.1 DataMart

Le **DataMart** constitue la principale cible de chargement des traitements ETL réalisés dans le cadre du projet. Il repose sur une base de données **MariaDB**.

Un DataMart est un espace de stockage de données structuré et orienté vers un besoin métier spécifique. Contrairement à une base transactionnelle classique, il est principalement conçu pour faciliter l'analyse et l'exploitation de données par les équipes métier.

Dans le contexte de X-FAB, le DataMart regroupe notamment des **données industrielles orientées vers la mesure de la performance des produits**. On y retrouve par exemple des informations issues des processus de fabrication, des mesures électriques, des résultats de tests ainsi que différents indicateurs utilisés pour analyser la qualité et le rendement des produits.

L'organisation des données repose sur un modèle décisionnel de type **constellation**. Ce modèle est constitué de plusieurs tables de faits partageant certaines dimensions communes.

3.2.2 Principales bibliothèques Python utilisées

La migration des traitements repose sur plusieurs bibliothèques Python permettant de couvrir les principaux besoins liés à la manipulation des données, aux connexions aux bases de données, à la configuration et aux tests.

Pandas

La bibliothèque **Pandas** est principalement utilisée pour la manipulation et la transformation des données.

Elle repose notamment sur la structure de données *DataFrame*, qui permet de manipuler des données tabulaires de manière efficace.

Dans le cadre du projet, Pandas est notamment utilisé pour :

- charger et structurer les données ;
- filtrer les lignes et les colonnes ;
- effectuer des jointures entre plusieurs jeux de données ;
- réaliser des agrégations ;
- transformer ou normaliser certaines valeurs ;
- gérer les données manquantes ;
- préparer les données avant leur chargement dans le DataMart.

SQLAlchemy

La bibliothèque **SQLAlchemy** est utilisée pour gérer les connexions et les interactions entre les scripts Python et les bases de données.

Elle permet notamment de créer et de centraliser les connexions aux différentes sources de données, puis d'exécuter des requêtes SQL depuis les traitements Python.

python-dotenv

La bibliothèque **python-dotenv** est utilisée afin de séparer les paramètres de configuration du code source.

Elle permet notamment de charger des variables d'environnement à partir d'un fichier `.env`. Ces variables peuvent contenir des informations telles que :

- les adresses des bases de données ;
- les ports utilisés ;
- les noms de bases ;

- les identifiants de connexion ;
- les chemins utilisés par les traitements ;
- différents paramètres propres à l’environnement.

Pytest

La bibliothèque **Pytest** est utilisée pour la mise en place des tests automatisés.

Dans le cadre de la migration, ces tests permettent notamment de vérifier le bon fonctionnement des différentes fonctions Python développées et de détecter plus rapidement d’éventuelles régressions lors des modifications du code.

3.2.3 Orchestration avec Prefect

Aujourd’hui, l’exécution des différents traitements ETL repose principalement sur une planification via **crontab**, associée à des fichiers de **logs** permettant de suivre leur exécution et d’identifier les éventuelles erreurs.

Bien que ce fonctionnement soit opérationnel, la gestion de plusieurs traitements devient plus complexe à mesure que leur nombre augmente. Il est notamment nécessaire de consulter les logs de manière individuelle et de maintenir séparément les différentes planifications.

L’utilisation de **Prefect** permet de simplifier cette gestion en centralisant l’orchestration, la planification et la supervision des ETL dans un même outil. Les traitements peuvent ainsi être suivis depuis une interface unique, avec une meilleure visibilité sur leur état, leur historique d’exécution, leurs logs et les éventuelles erreurs rencontrées. Prefect est un outil d’orchestration de workflows permettant de définir, planifier, exécuter et superviser des traitements de données. Il permet de transformer un script Python classique en un workflow structuré dont les différentes étapes peuvent être suivies individuellement.

Flows et Tasks

Dans Prefect, un traitement est principalement organisé autour de deux concepts : les **flows** et les **tasks**.

Un *flow* représente le workflow global correspondant à un traitement ou à un ETL. Il définit l’enchaînement général des différentes opérations à exécuter.

Les *tasks* représentent quant à elles les différentes étapes qui composent ce workflow. Par exemple, un traitement peut être séparé en plusieurs tâches :

- extraction des données ;

- transformation ;
- contrôle des données ;
- chargement du résultat ;
- génération d'un fichier ou d'un rapport.

Cette organisation permet de découper les traitements en étapes clairement identifiées et de faciliter leur suivi.

Planification

Prefect permet également de **planifier automatiquement l'exécution des traitements**.

Les ETL peuvent ainsi être exécutés selon une fréquence prédéfinie, par exemple quotidiennement, chaque semaine ou à un horaire spécifique, sans nécessiter d'intervention manuelle.

Cette fonctionnalité permet d'automatiser les traitements récurrents et de garantir leur exécution selon les besoins métier.

Logs

Lors de l'exécution d'un flow, Prefect centralise les **logs** générés par les différentes étapes.

Ces informations permettent de suivre le déroulement d'un traitement, d'identifier les différentes étapes exécutées et de disposer d'informations détaillées en cas d'erreur.

La centralisation des logs facilite ainsi le diagnostic et la maintenance des ETL.

Monitoring

Prefect dispose également d'une interface permettant de superviser les différents traitements.

Cette interface permet notamment de visualiser :

- les traitements en cours d'exécution ;
- les traitements terminés avec succès ;
- les traitements en erreur ;
- leur durée d'exécution ;
- l'historique des différentes exécutions.

Cette supervision offre une meilleure visibilité sur l'état global des traitements ETL et permet d'identifier rapidement les éventuels problèmes.

Gestion des erreurs

Prefect permet enfin d'intégrer différents mécanismes de gestion des erreurs.

Une tâche en échec peut par exemple être automatiquement relancée selon une stratégie définie. Les erreurs peuvent également être enregistrées dans les logs afin de faciliter leur analyse.

Cette gestion des erreurs permet de rendre les traitements plus robustes et de limiter les interventions manuelles lors de certains incidents temporaires, comme une indisponibilité momentanée d'une base de données.

3.2.4 Conteneurisation avec Docker

Les traitements Python sont également préparés pour être exécutés dans des environnements conteneurisés à l'aide de **Docker**.

Docker permet de regrouper une application ainsi que l'ensemble de ses dépendances dans un environnement isolé appelé **conteneur**.

Dans le cadre du projet, une image Docker peut notamment contenir :

- le code Python de l'ETL ;
- la version de Python nécessaire ;
- les bibliothèques utilisées ;
- les fichiers de configuration nécessaires à l'exécution.

L'utilisation de Docker apporte plusieurs avantages.

Tout d'abord, elle permet de garantir que le traitement s'exécute dans un environnement identique quel que soit le serveur sur lequel il est déployé. Elle limite ainsi les différences liées aux versions des bibliothèques ou à la configuration de la machine.

Elle facilite également le déploiement des traitements, puisqu'une même image peut être testée puis utilisée dans différents environnements

3.2.5 Outils de gestion et de collaboration

En complément des outils directement liés au développement et à l'exécution des traitements, plusieurs solutions sont utilisées afin d'assurer le suivi du projet, la documentation et la gestion du code source.

Jira

Jira est utilisé pour le suivi des différentes tâches du projet.

Chaque traitement à migrer peut être associé à une ou plusieurs tâches permettant de suivre son état d'avancement, depuis son analyse jusqu'à son déploiement.

L'outil permet également de centraliser les priorités, les travaux en cours et les tâches restant à réaliser.

Confluence

Confluence est utilisé comme outil de documentation interne.

Il permet de conserver une documentation structurée concernant notamment :

- le fonctionnement des ETL ;
- les règles métier identifiées ;
- les sources et les données de sortie ;
- les procédures de déploiement ;
- les informations utiles à la maintenance.

Cette documentation facilite le partage de connaissances et permet aux autres membres de l'équipe de comprendre plus facilement le fonctionnement des traitements.

GitLab

GitLab est utilisé pour la gestion du code source et le suivi des différentes versions des traitements.

Il repose sur le système de gestion de versions Git, qui permet de conserver l'historique des modifications réalisées sur le code et de travailler de manière collaborative.

GitLab permet notamment :

- de centraliser les dépôts de code ;
- de créer et gérer différentes branches de développement ;
- de suivre l'historique des modifications ;
- de faciliter les revues de code ;
- de préparer l'intégration des traitements dans des processus de déploiement automatisés.

L'association de Jira, Confluence et GitLab permet ainsi de couvrir les principaux besoins liés au suivi du projet, à la documentation et à la gestion du cycle de vie du code.

3.3 Stratégie de validation et tests

La migration des traitements ETL de R vers Python nécessite de vérifier que les résultats produits par les deux versions restent cohérents.

Pour cela, une stratégie de tests a été mise en place. Le principe consiste à exécuter le script R d'origine et sa version Python en utilisant les **mêmes sources de données** ainsi que la **même période de traitement**. Cette approche permet de comparer les résultats dans des conditions équivalentes.

Deux environnements distincts sont utilisés pour cette validation :

- **DMP**, correspondant à l'environnement de production ;
- **DMQ**, correspondant à l'environnement de développement et de test.

Les traitements historiques peuvent ainsi être exécutés sur les données de référence, tandis que les nouvelles versions Python sont validées dans l'environnement de test avant leur mise en production.

Afin d'automatiser cette phase de validation, un script Python de comparaison a été développé. Celui-ci permet de confronter les résultats produits par les deux traitements et de générer plusieurs indicateurs de contrôle.

Les principaux contrôles réalisés sont les suivants :

- comparaison du nombre total de lignes ;
- détection des enregistrements présents dans la version originale mais absents dans la copie ;
- détection des enregistrements présents dans la copie mais absents dans la version originale ;
- comparaison des valeurs pour les enregistrements communs ;
- calcul d'un taux global de concordance.

Le taux de concordance permet de mesurer le niveau de similarité entre les deux résultats. Il est calculé selon la formule suivante :

$$\text{Taux de concordance} = \left(1 - \frac{\text{Nombre total d'anomalies}}{\text{Nombre total d'enregistrements}} \right) \times 100$$

Le nombre total d'anomalies correspond à la somme :

Nombre total d'anomalies = Enregistrements manquants dans la copie + Enregistrements manquants dans l'original + Différences de valeurs

Un taux de concordance de **100%** signifie que les deux résultats sont strictement identiques selon les critères de comparaison définis.

Afin de faciliter l'analyse des écarts détectés, le script génère automatiquement trois fichiers de sortie :

- `missing_in_copy.csv` : enregistrements présents dans la version originale mais absents dans la copie ;
- `missing_in_original.csv` : enregistrements présents dans la copie mais absents dans la version originale ;
- `value_difference.csv` : enregistrements communs présentant des différences de valeurs.

3.3.1 Bilan de la validation

La stratégie de tests mise en place a permis de valider avec succès l'ensemble des ETL migrés de R vers Python.

Un exemple détaillé de migration d'un ETL, comprenant sa réécriture en Python ainsi que les résultats de validation, est présenté en annexe ??.

3.4 Travaux complémentaires

En parallèle de la migration des ETL existants, j'ai également participé à la conception et au développement de nouveaux traitements de données répondant à des besoins métier spécifiques.

Ces travaux complémentaires ont permis d'intervenir sur l'ensemble du cycle de vie d'un ETL, depuis l'expression du besoin et la rédaction des spécifications jusqu'au développement, aux tests, à la documentation et à la mise en production.

3.5 Travaux complémentaires

En parallèle du sujet principal de migration des ETL existants, j'ai également travaillé sur la conception de nouveaux traitements répondant à des besoins métier spécifiques.

Ces travaux sont encore en cours au moment de la rédaction du rapport et seront finalisés avant la fin du stage. Ils m'ont permis d'intervenir sur des problématiques allant de l'analyse du besoin et de la conception de l'architecture jusqu'au développement et à la préparation de la mise en production.

3.5.1 ETL Reject

Le premier travail complémentaire concerne la conception d'un nouvel ETL destiné à alimenter une application interne développée par un collègue, appelée **Lot Dispo**.

Cette application nécessite notamment de disposer d'informations concernant les wafers ayant été **scrappés**, c'est-à-dire rejetés au cours du processus de fabrication.

Dans ce contexte, j'ai été intégré au projet afin de concevoir le traitement permettant de récupérer ces données depuis une base source, de leur appliquer les transformations nécessaires, puis de les charger dans le **DataMart** afin qu'elles puissent être exploitées par l'application.

Le travail réalisé comprend notamment :

- l'analyse du besoin métier ;
- l'identification de la source de données ;
- la définition des données à extraire ;
- la conception de l'architecture du traitement ;
- la définition de la table cible dans le DataMart ;
- le développement du pipeline ETL ;
- la préparation des phases de test et de mise en production.

L'architecture générale conçue pour ce traitement peut être représentée de la manière suivante :

Base source → ETL Reject → DataMart → Application Lot Dispo

3.5.2 ETL Inline

Le second travail complémentaire porte sur la mise à disposition de données de **mé-**
trologie.

La métrologie correspond à l'ensemble des mesures réalisées afin de caractériser un wafer au cours de sa fabrication. Elle permet notamment de suivre différents paramètres physiques ou technologiques, tels que l'**épaisseur** de certaines couches ou encore l'**overlay**, qui correspond à la précision d'alignement entre différentes couches successives du wafer.

Les tables destinées à stocker ces informations sont déjà présentes dans le DataMart. L'objectif du projet est donc de concevoir un traitement permettant de récupérer les données de métrologie depuis une **API**, de les transformer si nécessaire, puis de les charger dans les tables correspondantes.

Le traitement peut être résumé par la chaîne suivante :

**API de métrologie → Extraction → Transformation → Chargement →
DataMart**

3.6 Difficultés rencontrées

Au cours du projet, plusieurs difficultés ont été rencontrées, principalement liées à la mise en place du nouvel environnement technique et à l'exécution de traitements sur des volumes de données importants.

3.6.1 Délais liés à la mise en production

La mise en production des nouveaux traitements a nécessité la mise en place d'un nouvel environnement reposant sur une machine virtuelle Linux.

Comme cet environnement était nouveau, plusieurs échanges et ajustements ont été nécessaires avec l'équipe IT. Lors des premières phases de configuration, certains accès n'étaient pas encore disponibles, notamment l'accès à certains fichiers, répertoires ou bases de données nécessaires au fonctionnement des ETL.

Ces contraintes ont entraîné plusieurs allers-retours avec l'équipe IT afin d'identifier les droits manquants, d'ouvrir les accès nécessaires et de valider progressivement la configuration de l'environnement.

Ces différents échanges ont parfois allongé les délais de mise en production. Ils m'ont néanmoins permis de mieux comprendre les contraintes liées à la préparation d'un environnement de production ainsi que l'importance de la coordination entre les équipes Data et IT.

3.6.2 Optimisation des traitements de nettoyage du DataMart

Une autre difficulté a été rencontrée lors d'un travail de *cleaning* du DataMart. Ce traitement avait pour objectif de supprimer certaines données anciennes, notamment celles dépassant une durée de conservation de trois ans.

Lors des premiers essais, certaines requêtes de suppression se sont révélées particulièrement coûteuses pour la base de données en raison du volume important de données à traiter. Elles ont entraîné une forte charge sur MariaDB et ont temporairement perturbé le fonctionnement de la base.

L'intervention rapide de l'équipe IT a permis de rétablir la situation et d'identifier

l'origine du problème.

Ces difficultés ont constitué des expériences importantes dans le cadre du stage, en apportant une meilleure compréhension des contraintes opérationnelles associées au Data Engineering dans un environnement industriel.

3.7 Conclusion

Ce projet de fin d'études réalisé au sein de X-FAB France avait pour objectif principal de contribuer à la modernisation des traitements de données existants, notamment à travers la migration de plusieurs ETL développés en R vers Python.

Les travaux réalisés ont permis de migrer et de valider avec succès une dizaine de traitements, tout en mettant en place un environnement Python plus homogène et mieux adapté aux pratiques actuelles de Data Engineering. La mise en œuvre de tests de non-régression, l'utilisation de nouveaux outils d'orchestration et de conteneurisation, ainsi que la participation à la conception de nouveaux ETL ont également permis d'élargir le périmètre du projet au-delà de la simple migration technique.

D'un point de vue personnel, ce stage m'a permis de découvrir le fonctionnement d'une grande entreprise industrielle et de travailler au sein d'une équipe à taille humaine, dynamique et collaborative. Il m'a permis de développer mon autonomie, ma capacité à apprendre rapidement de nouvelles technologies et à rechercher des solutions par moi-même, tout en sachant solliciter l'aide de mes collègues et de mes tuteurs lorsque cela était nécessaire.

Cette expérience m'a également permis de prendre davantage de responsabilités dans mes missions, de mieux comprendre le fonctionnement d'une équipe projet ainsi que les interactions entre les équipes métier, Data et IT. Elle m'a enfin permis de consolider mes compétences techniques en Data Engineering et de mieux appréhender les contraintes liées à la mise en production et à l'exploitation de traitements de données dans un environnement industriel.

A. Annexes